



(12)发明专利申请

(10)申请公布号 CN 110119648 A

(43)申请公布日 2019.08.13

(21)申请号 201810111564.0

G06K 9/40(2006.01)

(22)申请日 2018.02.05

G06K 9/62(2006.01)

(71)申请人 国家计算机网络与信息安全管理中心

地址 100029 北京市朝阳区裕民路甲3号

申请人 中国科学院声学研究所

(72)发明人 高圣翔 黄远 万辛 安茂波
李鹏 孙晓晨 沈亮 金鑫 徐及
刘珈麟 颜永红

(74)专利代理机构 北京方安思达知识产权代理有限公司 11472

代理人 陈琳琳 杨青

(51)Int.Cl.

G06K 9/00(2006.01)

G06K 9/34(2006.01)


权利要求书2页 说明书4页 附图1页

(54)发明名称

一种基于光学字符识别的传真图像分类方法

(57)摘要

本发明公开了一种基于光学字符识别的传真图像分类方法,所述方法包括:步骤1)对扫描得到的传真图像进行噪声消除;步骤2)对噪声消除后的传真图像进行二值化处理;步骤3)对步骤2)得到的二值化图像进行仿射变换校准文本;步骤4)利用OCR方法对步骤3)处理后的传真图像进行识别,得到编码为UTF-8的输出字符串和转写置信度;步骤5)对字符串进行关键词正则匹配,得到传真图像的分类。本发明的方法利用频谱噪声消除和灰度图像二值化的预处理,在满足实时性要求的前提下提升了电子扫描得到的传真图像的质量;使传真图像能够使用基于OCR的分类方法,由此实现了传真图像的自动化分类。



1. 一种基于光学字符识别的传真图像分类方法,包括:

步骤1) 对扫描得到的传真图像进行噪声消除;

步骤2) 对噪声消除后的传真图像进行二值化处理;

步骤3) 对步骤2) 得到的二值化图像进行仿射变换校准文本;

步骤4) 利用OCR方法对步骤3) 处理后的传真图像进行识别,得到编码为UTF-8的输出字符串和转写置信度;

步骤5) 对字符串进行关键词正则匹配,得到传真图像的分类。

2. 根据权利要求1所述的基于光学字符识别的传真图像分类方法,其特征在于,所述步骤1) 进一步包括:

步骤1-1) 计算传真图像的频谱 $G(u, v)$:

$$G(u, v) = \frac{1}{MN} \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} g[m, n] e^{-j2\pi(\frac{mu}{M} + \frac{nv}{N})}, \quad m, u = 0, 1, \dots, M-1; n, v = 0, 1, \dots, N-1$$

其中, $g[m, n]$ 为传真图像,其大小为M行N列, m, n 为像素空间位置, u, v 为频谱 $G(u, v)$ 的频域索引;

步骤1-2) 建立噪声污染的退化模型 $H(u, v)$:

$$H(u, v) = \frac{J_1(\pi\sqrt{u^2 + v^2})}{\pi\sqrt{u^2 + v^2}}$$

其中, $J_1(u, v)$ 为一阶贝塞尔函数;

步骤1-3) 由频谱 $G(u, v)$ 和退化模型 $H(u, v)$ 计算恢复模型 $H_w(u, v)$:

$$H_w(u, v) = \frac{H^*(u, v)}{|H(u, v)|^2 + \alpha}$$

其中, $H^*(u, v)$ 为 $H(u, v)$ 的共轭复数, α 为噪声功率谱与理想去噪图像功率谱的近似比,取值与传真数据相关;

步骤1-4) 由频谱 $G(u, v)$ 和恢复模型 $H_w(u, v)$ 估计去噪以后的图像频谱 $\hat{G}(u, v)$:

$$\hat{G}(u, v) = H_w(u, v)G(u, v)$$

步骤1-5) 计算去噪后的传真图像的灰度值 $\hat{g}[m, n]$:

$$\hat{g}[m, n] = \frac{1}{MN} \sum_{u=0}^{M-1} \sum_{v=0}^{N-1} \hat{G}(u, v) e^{j2\pi(\frac{mu}{M} + \frac{nv}{N})}, \quad m, u = 0, 1, \dots, M-1; n, v =$$

$0, 1, \dots, N-1$ 。

3. 根据权利要求1或2所述的基于光学字符识别的传真图像分类方法,其特征在于,所述步骤2) 具体包括:

步骤2-1) 利用图像中像素点灰度的最小值和最大值设定初始阈值 T_0 :

$$T_0 = \frac{1}{2}(R_{\max} - R_{\min})$$

其中, $R_{\min}$ 和 $R_{\max}$ 分别表示图像中灰度的最小值和最大值;令 $k=0$;

步骤2-2) 使用步骤1) 中的阈值 T_k 对图像进行分割:灰度值大于 T_k 的区域为目标区域 $R(i, j)$,灰度值小于 T_k 的区域为背景区域 $N(i, j)$;计算目标区域和背景区域的灰度均值 R_0 和

R_b:

$$R_o = \frac{\sum_{R(i,j) > T_k} R(i,j) \times N(i,j)}{\sum_{R(i,j) > T_k} N(i,j)}$$

$$R_b = \frac{\sum_{R(i,j) < T_k} R(i,j) \times N(i,j)}{\sum_{R(i,j) < T_k} N(i,j)}$$

步骤2-3) 计算新的阈值T_{k+1}:

$$T_{k+1} = \frac{R_o + R_b}{2}$$

步骤2-4) 判断T_k和T_{k+1}的差是否小于阈值;如果判断结果是肯定的,则最终阈值为T_{k+1};否则,转到步骤2-2);

步骤2-5) 使用步骤2-4) 中的阈值T_{k+1}对图像进行二值化处理:灰度值大于T_{k+1}的像素灰度置为255,小于T_{k+1}的像素灰度置为0。

一种基于光学字符识别的传真图像分类方法

技术领域

[0001] 本发明涉及传真图像自动分类方法,特别涉及一种基于光学字符识别的传真图像分类方法。

背景技术

[0002] 传真图像主要通过对出版物进行电子扫描得到,其主要组成是标准打印字体,手写字体和其他非文字单元(如图表)。传真图像分类技术可以根据指定的类别对传真图像进行分类,起到信息归类划分的作用。

[0003] 传统的传真图像分类主要依靠操作人员手工进行。这种依靠人工的分类方法,效率低下,准确率依赖于操作人员的经验和判断,缺乏客观统一指标。同时,传统的OCR(光学字符识别方法)对电子扫描文本的质量要求较高,不能直接用在传真图像上进行分类。

发明内容

[0004] 本发明的目的在于通过适当的图像预处理算法提高传真图像的质量,利用OCR方法对传真图像进行分类。

[0005] 为了实现上述目的,本发明提出了一种基于光学字符识别的传真图像分类方法,所述方法具体包括:

[0006] 步骤1) 对扫描得到的传真图像进行噪声消除;

[0007] 步骤2) 对噪声消除后的传真图像进行二值化处理;

[0008] 步骤3) 对步骤2) 得到的二值化图像进行仿射变换校准文本;

[0009] 步骤4) 利用OCR方法对步骤3) 处理后的传真图像进行识别,得到编码为UTF-8的输出字符串和转写置信度;

[0010] 步骤5) 对字符串进行关键词正则匹配,得到传真图像的分类。

[0011] 作为上述方法的一种改进,所述步骤1) 进一步包括:

[0012] 步骤1-1) 计算传真图像的频谱 $G(u, v)$:

[0013]

$$G(u, v) = \frac{1}{MN} \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} g[m, n] e^{-j2\pi(\frac{mu}{M} + \frac{nv}{N})}, \quad m, u = 0, 1, \dots, M-1; n, v = 0, 1, \dots, N-1$$

[0014] 其中, $g[m, n]$ 为传真图像,其大小为M行N列, m, n 为像素空间位置, u, v 为频谱 $G(u, v)$ 的频域索引;

[0015] 步骤1-2) 建立噪声污染的退化模型 $H(u, v)$:

$$[0016] \quad H(u, v) = \frac{J_1(\pi\sqrt{u^2 + v^2})}{\pi\sqrt{u^2 + v^2}}$$

[0017] 其中, $J_1(u, v)$ 为一阶贝塞尔函数;

[0018] 步骤1-3) 由频谱 $G(u, v)$ 和退化模型 $H(u, v)$ 计算恢复模型 $H_w(u, v)$:

$$[0019] \quad H_w(u, v) = \frac{H^*(u, v)}{|H(u, v)|^2 + \alpha}$$

[0020] 其中, $H^*(u, v)$ 为 $H(u, v)$ 的共轭复数, α 为噪声功率谱与理想去噪图像功率谱的近似比, 取值与传真数据相关;

[0021] 步骤1-4) 由频谱 $G(u, v)$ 和恢复模型 $H_w(u, v)$ 估计去噪以后的图像频谱 $\hat{G}(u, v)$:

$$[0022] \quad \hat{G}(u, v) = H_w(u, v)G(u, v)$$

[0023] 步骤1-5) 计算去噪后的传真图像的灰度值 $\hat{g}[m, n]$:

$$[0024] \quad \hat{g}[m, n] = \frac{1}{MN} \sum_{u=0}^{M-1} \sum_{v=0}^{N-1} \hat{G}(u, v) e^{j2\pi(\frac{mu}{M} + \frac{nv}{N})}, \quad m, u = 0, 1, \dots, M-1; n, v = 0, 1, \dots, N-1。$$

[0025] 作为上述方法的一种改进, 所述步骤2) 具体包括:

[0026] 步骤2-1) 利用图像中像素点灰度的最小值和最大值设定初始阈值 T_0 :

$$[0027] \quad T_0 = \frac{1}{2}(R_{\max} - R_{\min})$$

[0028] 其中, $R_{\min}$ 和 $R_{\max}$ 分别表示图像中灰度的最小值和最大值; 令 $k=0$;

[0029] 步骤2-2) 使用步骤1) 中的阈值 T_k 对图像进行分割: 灰度值大于 T_k 的区域为目标区域 $R(i, j)$, 灰度值小于 T_k 的区域为背景区域 $N(i, j)$; 计算目标区域和目标区域的灰度均值 R_o 和 R_b :

$$[0030] \quad R_o = \frac{\sum_{R(i,j) > T_k} R(i, j) \times N(i, j)}{\sum_{R(i,j) > T_k} N(i, j)}$$

$$[0031] \quad R_b = \frac{\sum_{R(i,j) < T_k} R(i, j) \times N(i, j)}{\sum_{R(i,j) < T_k} N(i, j)}$$

[0032] 步骤2-3) 计算新的阈值 T_{k+1} :

$$[0033] \quad T_{k+1} = \frac{R_o + R_b}{2}$$

[0034] 步骤2-4) 判断 T_k 和 T_{k+1} 的差是否小于阈值; 如果判断结果是肯定的, 则最终阈值为 T_{k+1} ; 否则, 转到步骤2-2);

[0035] 步骤2-5) 使用步骤2-4) 中的阈值 T_{k+1} 对图像进行二值化处理: 灰度值大于 T_{k+1} 的像素灰度置为255, 小于 T_{k+1} 的像素灰度置为0。

[0036] 本发明的优点在于:

[0037] 本发明的方法利用频谱白噪声消除和灰度图像二值化的预处理, 在满足实时性要求的前提下提升了电子扫描得到的传真图像的质量; 使传真图像能够使用基于光学字符识别的分类方法, 由此实现了传真图像的自动化分类。

附图说明

[0038] 图1是本发明的基于光学字符识别的传真图像分类方法的流程图。

具体实施方式

[0039] 现结合附图对本发明作进一步的描述。

[0040] 参考图1,本发明的方法包括以下步骤:

[0041] 步骤101) 对电子扫描得到的传真图像进行噪声消除;

[0042] 步骤101-1) 计算传真图像的频谱 $G(u, v)$:

[0043]

$$G(u, v) = \frac{1}{MN} \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} g[m, n] e^{-j2\pi(\frac{mu}{M} + \frac{nv}{N})}, \quad m, u = 0, 1, \dots, M-1; n, v = 0, 1, \dots, N-1$$

[0044] 其中, $g[m, n]$ 为传真图像, 其大小为 M 行 N 列, m, n 为像素空间位置, u, v 为频谱 $G(u, v)$ 的频域索引;

[0045] 步骤101-2) 建立噪声污染的退化模型 $H(u, v)$:

$$H(u, v) = \frac{J_1(\pi\sqrt{u^2 + v^2})}{\pi\sqrt{u^2 + v^2}}$$

[0047] 其中, $J_1(u, v)$ 为一阶贝塞尔函数;

[0048] 步骤101-3) 由频谱 $G(u, v)$ 和退化模型 $H(u, v)$ 计算恢复模型 $H_w(u, v)$:

$$H_w(u, v) = \frac{H^*(u, v)}{|H(u, v)|^2 + \alpha}$$

[0050] 其中, $H^*(u, v)$ 为 $H(u, v)$ 的共轭复数, α 为噪声功率谱与理想去噪图像功率谱的近似比, 取值与传真数据相关, 本专利中取值为0.08。

[0051] 步骤101-4) 由频谱 $G(u, v)$ 和恢复模型 $H_w(u, v)$ 估计去噪以后的图像频谱 $\hat{G}(u, v)$:

$$\hat{G}(u, v) = H_w(u, v) G(u, v)$$

[0053] 步骤101-5) 计算去噪图像的灰度值 $\hat{g}[m, n]$:

$$\hat{g}[m, n] = \frac{1}{MN} \sum_{u=0}^{M-1} \sum_{v=0}^{N-1} \hat{G}(u, v) e^{j2\pi(\frac{mu}{M} + \frac{nv}{N})}, \quad m, u = 0, 1, \dots, M-1; n, v = 0, 1, \dots, N-1。$$

[0055] 步骤102) 将噪声消除后的传真图像进行基于阈值划分的二值化处理, 其中背景置为白, 文字置为黑; 所述步骤102) 具体包括:

[0056] 步骤102-1) 利用图像中像素点灰度的最小值和最大值设定初始阈值 T_0 :

$$T_0 = \frac{1}{2}(R_{\max} - R_{\min})$$

[0058] 其中, $R_{\min}$ 和 $R_{\max}$ 分别表示图像中灰度的最小值和最大值; 令 $k=0$;

[0059] 步骤102-2) 使用步骤1) 中的阈值 T_k 对图像进行分割, 设灰度值大于 T_k 的区域为目标区域 $R(i, j)$, 灰度值小于 T_k 的区域为背景区域 $N(i, j)$; 计算目标区域和背景区域的灰度均值 R_o 和 R_b :

$$R_o = \frac{\sum_{R(i, j) > T_k} R(i, j) \times N(i, j)}{\sum_{R(i, j) > T_k} N(i, j)}$$

$$[0061] \quad R_b = \frac{\sum_{R(i,j) < T_k} R(i,j) \times N(i,j)}{\sum_{R(i,j) < T_k} N(i,j)}$$

[0062] 步骤102-3) 计算新的阈值 T_{k+1} :

$$[0063] \quad T_{k+1} = \frac{R_o + R_b}{2}$$

[0064] 步骤102-4) 判断 T_k 和 T_{k+1} 的差是否小于阈值;如果判断结果是肯定的,则最终阈值为 T_{k+1} ;否则,转到步骤102-2);

[0065] 步骤102-5) 使用步骤102-4) 中的阈值 T_{k+1} 对图像进行二值化处理:灰度值大于 T_{k+1} 的像素灰度置为255,小于 T_{k+1} 的像素灰度置为0。

[0066] 步骤103) 对去噪二值化的传真图像进行仿射变换校准;

[0067] 步骤104) 利用OCR方法对步骤103) 处理后的传真图像进行识别,得到编码为UTF-8的输出字符串和转写置信度;

[0068] 步骤105) 对字符串关键词进行正则匹配,获得传真图像的类型。

[0069] 最后所应说明的是,以上实施例仅用以说明本发明的技术方案而非限制。尽管参照实施例对本发明进行了详细说明,本领域的普通技术人员应当理解,对本发明的技术方案进行修改或者等同替换,都不脱离本发明技术方案的精神和范围,其均应涵盖在本发明的权利要求范围当中。




图1